

COE-835 Controle adaptativo

Trabalho 8

Grupo: Guilherme Pires Sales de Carvalho
Matheus Ferreira dos Reis
Renan Salles de Freitas

Algoritmo: Adaptive Backstepping Control - Reduced Order Observer

Caso: $n = 2$ (ordem da planta)
 $n^* = 2$ (grau relativo)
 $n_p = 3$ (# de parâmetros)

Conteúdo

1	Backstepping - Observador de ordem reduzida	2
2	Implementação	6
3	Resultados das simulações	7
3.1	Simulação #1	7
3.2	Simulação #2	11
3.3	Simulação #3	12
4	Discussão	16

1 Backstepping - Observador de ordem reduzida

Este trabalho visa complementar o trabalho 7, modificando o observador completo por um observador de ordem reduzida, também chamado de observador de Luenberger. A formulação teórica passa pela ideia geral de um observador de ordem reduzida, exemplifica para o caso do sistema de segunda ordem deste trabalho e, por último, desenvolvemos o algoritmo backstepping para este observador e caso $n = 2$, $n^* = 2$.

Considere uma planta descrita pelo seguinte sistema em espaço de estados:

$$\begin{aligned}\dot{x} &= Ax + Bu \\ y &= Cx\end{aligned}\tag{1}$$

Suponha que os primeiros m estados podem ser obtidos diretamente pela medida da saída do sistema, ou seja, o sistema pode ser particionando:

$$\begin{aligned}\dot{x}_1 &= A_{11}x_1 + A_{12}x_2 + B_1u \\ \dot{x}_2 &= A_{21}x_1 + A_{22}x_2 + B_2u \\ y &= C_1x_1\end{aligned}\tag{2}$$

e $x_1 = C_1^{-1}y$. Um observador de ordem reduzida pode ser usado para estimar os $x_2 \in \mathbb{R}^{n-m}$ estados faltantes. Define-se:

$$\chi = x_2 + Ny\tag{3}$$

Pode-se demonstrar que a dinâmica de χ é descrita como:

$$\begin{aligned}\chi &= Q\chi + Ry + Su \\ Q &= A_{22} + NC_1A_{12} \\ R &= -QN + (A_{21} + NC_1A_{11})C_1^{-1} \\ S &= B_2 + NC_1B_1\end{aligned}\tag{4}$$

Derivando a equação 3, obtemos:

$$\begin{aligned}\dot{\chi} &= \dot{x}_2 + NC_1\dot{x}_1 \\ &= (A_{21}x_1 + A_{22}x_2 + B_2u) + NC_1(A_{11}x_1 + A_{12}x_2 + B_1u) \\ &= (A_{22} + NC_1A_{12})x_2 + (A_{21} + NC_1A_{11})x_1 + (B_2 + NC_1B_1)u \\ &= (A_{22} + NC_1A_{12})x_2 + (A_{22} + NC_1A_{12})Ny - (A_{22} + NC_1A_{12})Ny + (A_{21} + NC_1A_{11})x_1 + (B_2 + NC_1B_1)u \\ &= (A_{22} + NC_1A_{12})(x_2 + Ny) - (A_{22} + NC_1A_{12})Ny + (A_{21} + NC_1A_{11})C_1^{-1}y + (B_2 + NC_1B_1)u \\ &= Q\chi + [-QN + (A_{21} + NC_1A_{11})C_1^{-1}]y + Su \\ &= Q\chi + Ry + Su\end{aligned}\tag{5}$$

Neste trabalho, consideramos o sistema:

$$\begin{aligned}\dot{x}_1 &= x_2 - a_1y \\ \dot{x}_2 &= k_p u - a_0y\end{aligned}\tag{6}$$

onde os parâmetros a_1 , a_0 e k_p são desconhecidos. Para esta formulação apenas a saída do sistema y está disponível, portanto x_2 não é conhecido e deve ser estimado. Podemos reescrever o sistema 6:

$$\begin{aligned}\dot{x} &= Ax - F(y, u)^\top \theta \\ A &= \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, F(y, u)^\top = [B(u) \quad \Phi(y)], \Phi(y) = \begin{bmatrix} -y & 0 \\ 0 & -y \end{bmatrix}, B(u) = \begin{bmatrix} 0 \\ u \end{bmatrix}, \theta = \begin{bmatrix} k_p \\ a_1 \\ a_0 \end{bmatrix} \\ y &= e_1^\top x \\ e_1 &= \begin{bmatrix} 1 \\ 0 \end{bmatrix}\end{aligned}\tag{7}$$

No trabalho 7, para estimar os estados, utilizamos os filtros abaixo:

$$\begin{aligned}\dot{\xi} &= A_0 \xi + ky \\ \dot{\Omega}^\top &= A_0 \Omega^\top + F^\top \\ k &= \begin{bmatrix} k_1 \\ k_2 \end{bmatrix}, A_0 = A - ke_1^\top = \begin{bmatrix} -k_1 & 1 \\ -k_2 & 0 \end{bmatrix}\end{aligned}\tag{8}$$

Os valores de k devem ser escolhidos de forma que A_0 seja Hurwitz. E, dessa forma, o estado estimado pode ser escrito como:

$$\hat{x} = \xi + \Omega^\top \theta\tag{9}$$

Como no trabalho 7, verifica-se que a dinâmica do estimador é igual à dinâmica da planta 6.

Para o caso do observador de ordem reduzida, define-se:

$$\chi = x_2 + Ny\tag{10}$$

E derivando, obtemos:

$$\begin{aligned}\dot{\chi} &= (-a_0 y + k_p u) + N(x_2 - a_1 y) \\ &= Nx_2 - (a_0 + Na_1)y + k_p u \\ &= N(\chi - Ny) - (a_0 + a_1)y + k_p u \\ &= N\chi - N^2 y + F^\top \theta \\ F^\top &= [u \quad -Ny \quad -y], \theta = [k_p \quad a_1 \quad a_0]^\top\end{aligned}\tag{11}$$

Para o sistema de ordem reduzida, os filtros são:

$$\begin{aligned}\dot{\xi} &= N\xi - N^2 y \\ \dot{\Omega}^\top &= N\Omega^\top + F^\top \\ N &< 0\end{aligned}\tag{12}$$

E o estado estimado será:

$$\hat{\chi} = \xi + \Omega^\top \theta \quad (13)$$

$$\dot{\hat{\chi}} = \dot{\xi} + \Omega^\top \dot{\theta} \quad (14)$$

$$\begin{aligned} &= (N\xi - N^2y) + (N\Omega^\top + F^\top)\theta \\ &= N(\xi + \Omega^\top \theta) - N^2y + F^\top \theta \\ \dot{\hat{\chi}} &= N\hat{\chi} - N^2y + F^\top \theta \end{aligned} \quad (15)$$

Porém, Ω é uma matriz e opta-se pela redução das ordens dos filtros. Observe que $\Omega^\top = [v_0 \mid \Xi]$ e, pela equação 12, temos que:

$$\dot{v}_0 = Nv_0 + u \quad (16)$$

$$\dot{\Xi} = N\Xi + [-N \quad -1] y \quad (17)$$

Introduzem-se dois novos filtros, para substituir os filtros da equação 12:

$$\dot{\lambda} = N\lambda + u \quad (18)$$

$$\dot{\eta} = N\eta + y \quad (19)$$

É fácil verificar que, para esta planta de segunda ordem sem zeros ($m = 0$), $v_0 = \lambda$. Agora vamos demonstrar que:

$$\Xi = -[N\eta \quad \eta] \quad (20)$$

Derivando 20, temos:

$$\begin{aligned} \dot{\Xi} &= -[N\dot{\eta} \quad \dot{\eta}] \\ &= -[N^2\eta + Ny \quad N\eta + y] \\ &= -N[N\eta \quad \eta] + [-N \quad -1] y \\ &= N\Xi + [-N \quad -1] y \end{aligned}$$

E assim chegamos na equação 17. Também temos a relação:

$$\xi = -N^2\eta \quad (21)$$

Derivando a equação 21, obtemos:

$$\begin{aligned} \dot{\xi} &= -N^2(N\eta + y) \\ &= N(-N^2\eta - y) = N\xi - N^2y \end{aligned}$$

E assim chegamos na equação 12. O projeto backstepping agora segue como no trabalho anterior. Primeiro, fazemos a mudança de coordenadas em \mathbf{z} :

$$\begin{aligned} z_1 &= y - y_r \\ z_2 &= v_0 - \alpha_1 - \hat{\rho}\dot{y}_r \end{aligned} \quad (22)$$

onde ρ é estimativa de $\frac{1}{k_p}$. O controle virtual α_1 , a lei de controle u e as leis de adaptação $\dot{\theta}$ e $\dot{\rho}$ são obtidas pelo método de Lyapunov. Derivando z_1 , obtemos:

$$\dot{z}_1 = k_p \alpha_1 + \xi + \bar{\omega}^\top \theta + \epsilon - k_p \tilde{\rho} \dot{y}_r + k_p z_2 - N y \quad (23)$$

$$\alpha_1 = \hat{\rho} \bar{\alpha}_1 \quad (24)$$

$$\dot{z}_1 = \bar{\alpha}_1 + \xi_2 + \bar{\omega}^\top \theta + \epsilon_2 - k_p (\dot{y}_r + \bar{\alpha}_1) \tilde{\rho} + k_p z_2 - N y \quad (25)$$

E escolhemos a primeira função estabilizante:

$$\bar{\alpha}_1 = -c_1 z_1 - d_1 z_1 - \xi_2 - \bar{\omega}^\top \hat{\theta} + N y \quad (26)$$

A dinâmica de z_1 pode ser reescrita como:

$$\dot{z}_1 = -c_1 z_1 - d_1 z_1 + \epsilon_2 + [\omega - \hat{\rho}(\dot{y}_r + \bar{\alpha}_1)e_1]^\top \tilde{\theta} - k_p (\dot{y}_r + \bar{\alpha}_1) \tilde{\rho} + \hat{k}_p z_2 \quad (27)$$

Escolhe-se a função de Lyapunov:

$$2V_1 = z_1^2 + \tilde{\theta}^\top \Gamma^{-1} \tilde{\theta} + |k_p| \gamma^{-1} \tilde{\rho}^2 + \frac{1}{2d_1} \epsilon^\top P \epsilon \quad (28)$$

Nessas condições, é possível que a atualização de $\hat{\rho}$ é dada pela equação:

$$\dot{\hat{\rho}} = -\gamma z_1 \text{sign}(k_p)(\dot{y}_r + \bar{\alpha}_1) \quad (29)$$

Derivando z_2 , obtemos:

$$\dot{z}_2 = \dot{v} - \hat{\rho} \ddot{y}_r - \dot{\hat{\rho}} \dot{y}_r - \dot{\alpha}_1 \quad (30)$$

$$= N v + u - \hat{\rho} \ddot{y}_r - \beta - \frac{\partial \alpha_1}{\partial y} (\omega^\top \tilde{\theta} + \epsilon_2) - \frac{\partial \alpha_1}{\partial \hat{\theta}} \dot{\hat{\theta}} \quad (31)$$

$$\beta = \frac{\partial \alpha_1}{\partial y} (\xi + \omega^\top \hat{\theta} - N y) + \frac{\partial \alpha_1}{\partial \eta} (N \eta + y) + \frac{\partial \alpha_1}{\partial \dot{y}_r} \dot{y}_r + (\dot{y}_r + \frac{\partial \alpha_1}{\partial \hat{\rho}}) \dot{\hat{\rho}} \quad (32)$$

Escolhe-se a função de Lyapunov:

$$V_2 = V_1 + \frac{1}{2} z_2^2 + \frac{1}{4d_2} \epsilon^\top P \epsilon \quad (33)$$

É possível mostrar que a atualização de parâmetros e a lei de controle são:

$$\hat{\theta} = \Gamma \tau_2 \quad (34)$$

$$\tau_1 = (\omega - \hat{\rho}(\dot{y}_r + \bar{\alpha}_1)e_1) z_1 \quad (35)$$

$$\tau_2 = \tau_1 - z_2 \frac{\partial \alpha_1}{\partial y} \omega \quad (36)$$

$$u = -N v - c_2 z_2 + \beta + \hat{\rho} \ddot{y}_r + \frac{\partial \alpha_1}{\partial \hat{\theta}} \dot{\hat{\theta}} - d_2 z_2 \left(\frac{\partial \alpha_1}{\partial y} \right)^2 - \hat{k}_p z_1 \quad (37)$$

2 Implementação

Para a implementação, só é preciso computar os filtros:

$$\dot{\lambda} = N\lambda + u \quad (38)$$

$$\dot{\eta} = N\eta + y \quad (39)$$

Temos ainda que $\alpha = \hat{\rho}(-c_1 z_1 - d_1 d_1 - \xi - \bar{\omega}^\top \hat{\theta})$. Logo:

$$\frac{\partial \alpha_1}{\partial y} = -\hat{\rho}(c_1 + d_1) + \hat{\rho} e_2^\top \hat{\theta} + \hat{\rho} N \quad (40)$$

$$\frac{\partial \alpha_1}{\partial \eta} \frac{d\eta}{dt} = \hat{\rho} \left(N^2 \frac{d\eta}{dt} + \begin{bmatrix} 0 & N \frac{d\eta}{dt} & \frac{d\eta}{dt} \end{bmatrix} \hat{\theta} \right) \quad (41)$$

$$\frac{\partial \alpha_1}{\partial y_r} = \hat{\rho}(c_1 + d_1) \quad (42)$$

$$\frac{\partial \alpha_1}{\partial \hat{\theta}} = -\hat{\rho} \bar{\omega} \quad (43)$$

$$\frac{\partial \alpha_1}{\partial \hat{\rho}} = -(c_1 + d_1)(y - y_r) + N^2 \eta - \bar{\omega}^\top \hat{\theta} + N y \quad (44)$$

```

1  %-----
2  %
3  % COE-835 Controle adaptativo
4  %
5  % Script para simular o trabalho 8
6  %
7  % Backstepping : n = 2      Second and third order plant
8  %                n* = 2     Relative degree
9  %                np = 3     Adaptive parameters
10 % Caso com observador de ordem reduzida
11 %-----
12
13 function dx = backstepping_red(t,x)
14
15 global A B thetas N c1 c2 d1 d2 Gamma gamma kp a w e1;
16
17 y          = x(1:2);
18 theta      = x(3:5);
19 lambda     = x(6);
20 eta        = x(7);
21 rho        = x(8);
22
23 %% Input
24 yr = a(1) * sin(w(1)*t) + a(2) * sin(w(2)*t);
25 dyr = a(1) * w(1) * cos(w(1)*t) + a(2) * w(2) * cos(w(2)*t);
26 ddyr = -a(1) * w(1)^2 * sin(w(1)*t) - a(2) * w(2)^2 * sin(w(2)*t);
27
28 Phi = [-y(1) 0;0 -y(1)];
29
30 %% Variables 1
31 xi = -N^2 * eta;
32 Xi = -[N*eta eta];
33 v1 = lambda(1);
34 omega_bar = [0, (Xi - y(1)*e1')]';
35 omega = [v1, (Xi - y(1)*e1')]';

```

```

36
37 %% Z
38 z1 = y(1) - yr;
39 alpha_bar = -c1*z1 - d1*z1 - xi - omega_bar'*theta + N*y(1);
40 alpha_1 = rho * alpha_bar;
41 z2 = v1 - rho*dyr - alpha_1;
42
43 %% Filtro eta
44 deta = N*eta + y(1);
45
46 %% dalpha/dt
47 dady = rho * (- c1 - d1 + [0,e1']*theta + N);
48 dadeta_deta = rho * (N^2 * deta + [0, N*deta, deta]*theta);
49 dadyr = rho*(c1 + d1);
50 dadtheta = - rho * omega_bar';
51 dadrho = -(c1 + d1)*(y(1) - yr) - xi - omega_bar'*theta + N*y(1);
52
53
54 %% Variables 2
55 tau_1 = (omega - rho*(dyr + alpha_bar)*[e1',0]')*z1;
56 tau_2 = tau_1 - z2 * (dady * omega);
57
58 %% Atualização dos parâmetros
59 dtheta = Gamma * tau_2;
60 drho = - gamma * z1 * sign(kp) * (dyr + alpha_bar);
61 beta = dady * (xi + omega'*theta - N*y(1)) + ...
62       dadeta_deta + dadyr * dyr + (dyr + dadrho) * drho;
63 u = -N*v1 -c2*z2 + beta + rho*ddyr + dadtheta*dtheta - d2*z2*(dady)^2 - ...
64     theta(1)*z1;
65
66 %% Filtros
67 dlambda = N*lambda + u;
68
69
70 %% Planta
71 F = [[0 1]'*u Phi];
72 dy = A*y + F*thetas;
73
74 %% Translation
75 dx = [dy' dtheta' dlambda' deta' drho]';

```

3 Resultados das simulações

Nas simulações, procuramos avaliar o comportamento do sistema para as seguintes condições: (i) condições iniciais $\theta(0)$ e $y(0)$; (ii) Parâmetros da planta e do modelo; (iii) ganho de adaptação Γ .

Apresentaremos os resultados obtidos através de simulações no ambiente **Matlab/Simulink** e os discutiremos na próxima seção. Para todos os casos $N = -1$.



3.1 Simulação #1

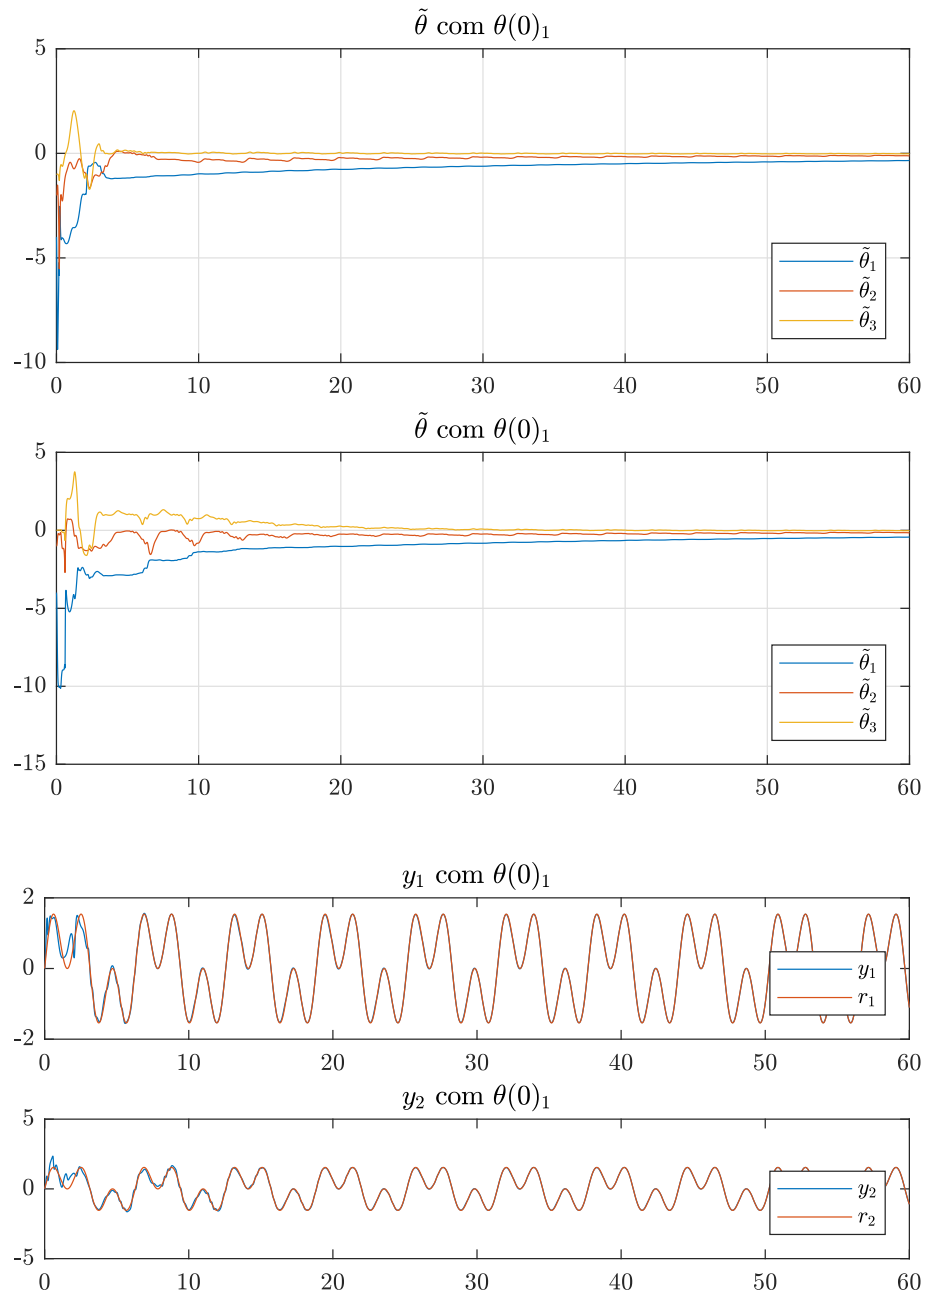
Inicialmente, desejamos verificar o comportamento do sistema para variações nas condições iniciais.

Simulação 1.1: $\theta(0)$

$$y = \frac{5}{s^2 + 2s + 1}u, \quad \theta(0) = 0 \text{ e } 1, \quad y(0) = 0, \quad \Gamma = 10\mathbf{I}_3,$$





$$y_r = \sin(t) + \sin(3t).$$






Simulação 1.2: $y(0)$

$$y = \frac{5}{s^2 + 2s + 1}u, \quad \theta(0) = 0, \quad y(0) = 0 \text{ e } 5, \quad \Gamma = 10\mathbf{I}_3, \\ y_r = \sin(t) + \sin(3t).$$





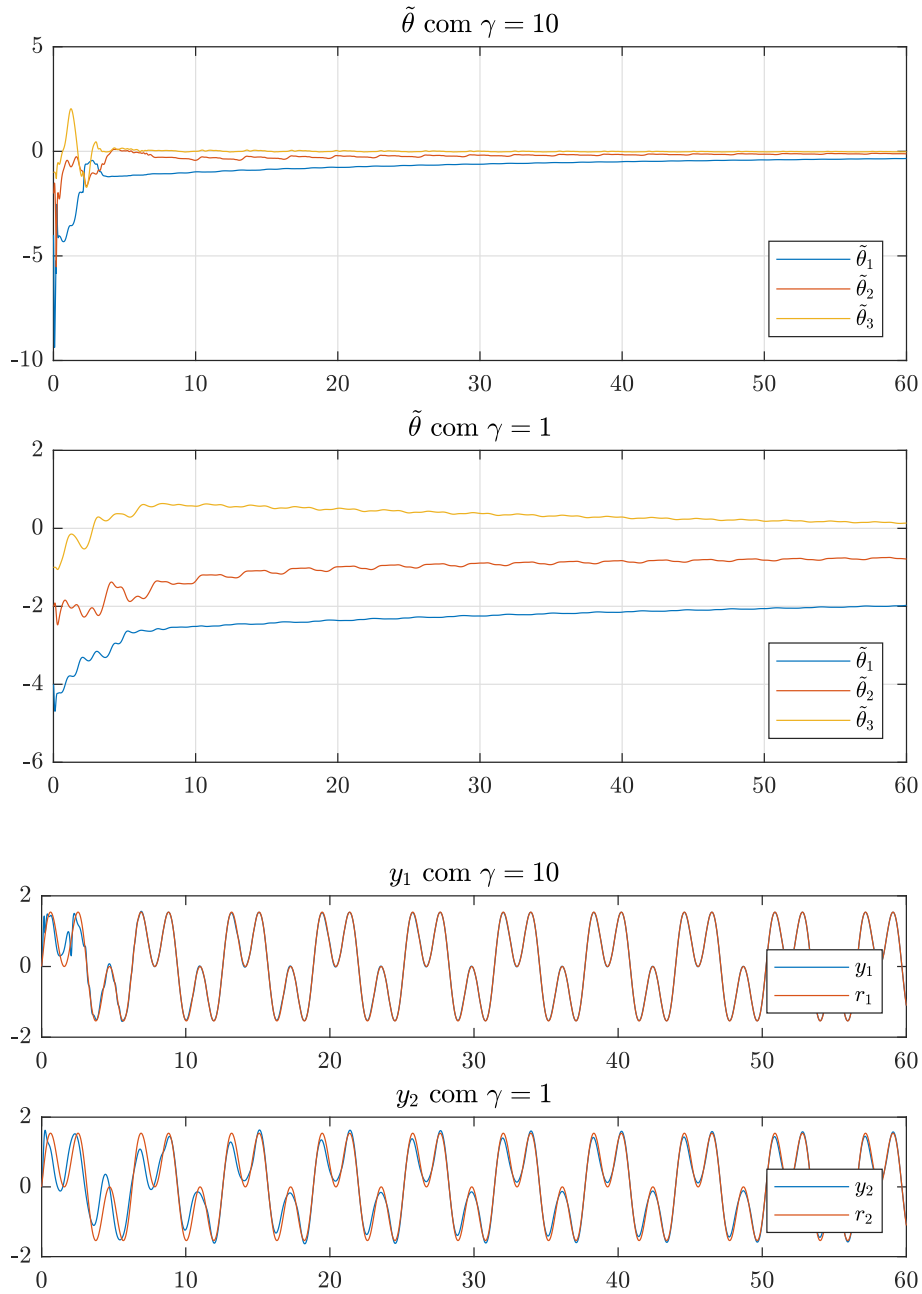


3.2 Simulação #2

Verificamos o comportamento do sistema para variações no parâmetro de adaptação Γ .

$$y = \frac{5}{s^2 + 2s + 1}u, \quad \theta(0) = 0, \quad y(0) = 0, \quad \Gamma = 1 \text{ e } 10 \mathbf{I}_3, \\ y_r = \sin(t) + \sin(3t).$$









3.3 Simulação #3


Verificamos o comportamento do sistema para variações na planta e modelo.

Simulação 3.1: planta

$$y = \frac{5}{s^2 + 2s + 1} u e^{\frac{5}{s^2 - 2s + 1} u}, \quad \theta(0) = 0, \quad y(0) = 0, \quad \Gamma = 10 \mathbf{I}_3,$$

$$y_r = \sin(t) + \sin(3t).$$

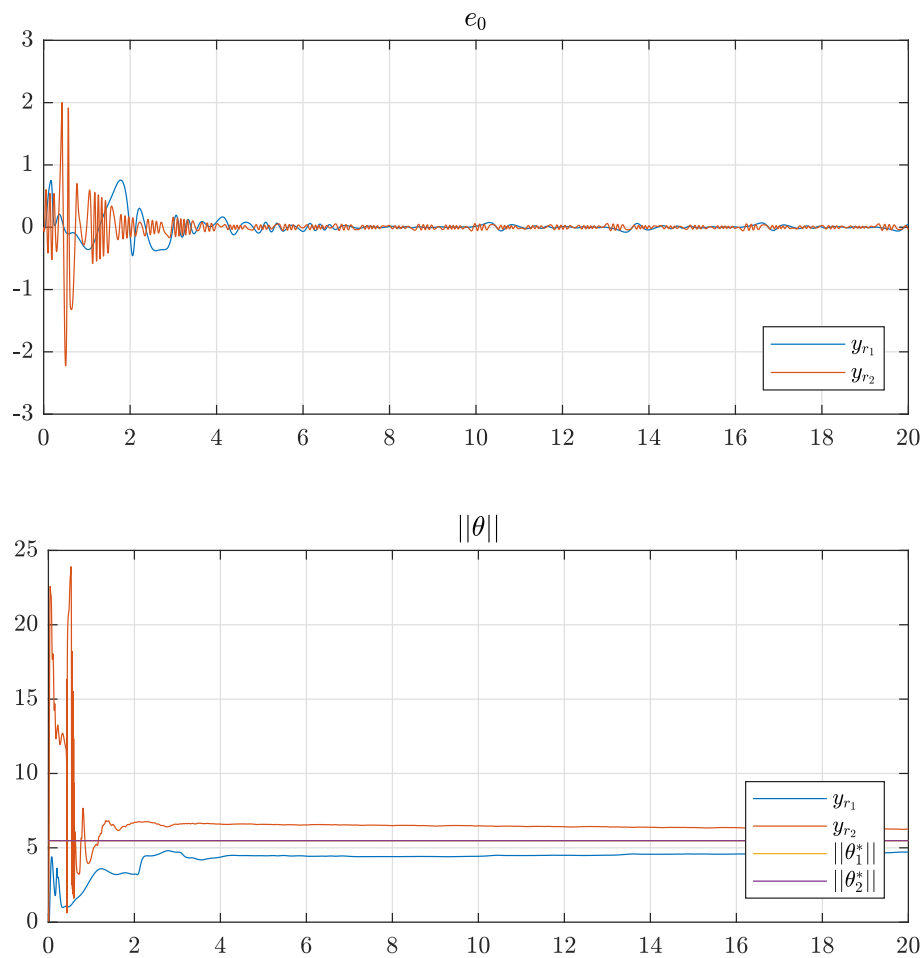


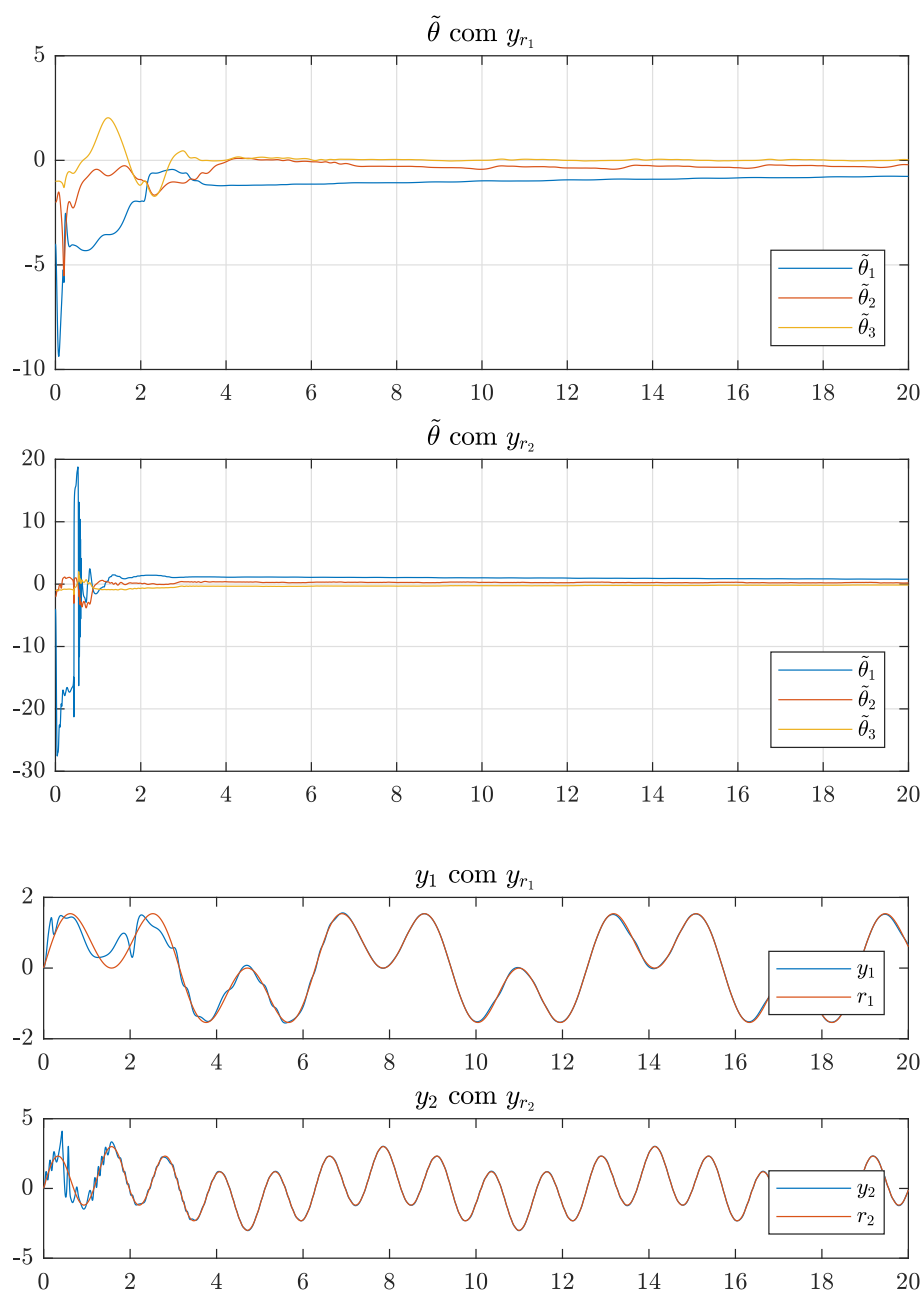


Simulação 3.2: modelo

$$y = \frac{5}{s^2 + 2s + 1}u \quad \theta(0) = 0, \quad y(0) = 0, \quad \Gamma = 10 \mathbf{I}_3,$$

$$y_r = \sin(t) + \sin(3t) \text{ e } \sin(t) + 2\sin(5t).$$





4 Discussão

A **simulação #1** mostra o comportamento do sistema para variações nas condições iniciais. A rapidez da convergência depende de quão próximo os parâmetros estimados estão dos parâmetros reais. A simulação mostrou um comportamento semelhante para ambos os casos. Quando deslocamos o $y(0)$, na simulação 1.2, os sistemas também apresentam comportamento semelhante, pois a variável de controle u é alterada e não apresenta saturação, compensando a condição inicial.

A **simulação #2** mostra o comportamento do sistema para variações no ganho de adaptação Γ . Podemos verificar convergência mais rápida quando o Γ é maior, porém também observamos maiores oscilações e picos de erro.

A **simulação #3** mostra o comportamento do sistema para variações na planta. Escolhemos plantas instáveis e estáveis. Podemos observar que, em ambos os casos, o sinal de controle foi capaz de corrigir o erro, sem muitas dificuldades. O comportamento dos sistemas é semelhante. A alteração do modelo, na simulação 3.2, mostrou que modelos mais complexos, com frequências mais altas e maiores amplitudes, demoram mais para convergir.